Forme di parallelismo

Note in aggiunta alla Sez. 3.6 del libro di testo

M. Danelutto

AEa 2020—21

Misure (primitive)

• Latenza tempo fra l'inizio di un calcolo e la produzione del relativo risultato

• Tempo di completamento (di m calcoli diversi) tempo fra l'inizio del primo calcolo e la terminazione dell'ultimo

Tempo di servizio (nel calcolo di m task diversi) tempo che intercorre fra la produzione di due risultati consecutivi o fra l'inizio di due calcoli consecutivi

Throughput

(nel calcolo di **m** task diversi) numero di calcoli completati per unità di tempo (inverso del tempo di servizio)

- Diminuire la latenza significa rendere disponibile prima il risultato del singolo calcolo
- Diminuire il tempo si servizio significa aumentare il throughput

Misure (derivate)

• Speedup(n)

rapporto fra il miglior tempo sequenziale e il tempo utilizzato in parallelo con grado di parallelismo pari a n

$$speedup(n) = Tseq / T(n)$$

• Scalabilità(n)

rapporto fra il tempo impiegato a calcolare con grado di parallelismo 1 e quello impiegato con grado di parallelismo n

$$scalab(n) = T(1) / T(n)$$

Tempo ideale(n)

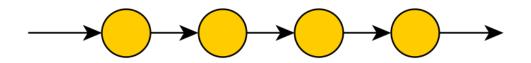
rapporto fra il tempo sequenziale e il grado di parallelismo n

$$Tid(n) = Tseq / n$$

Efficienza(n)

rapporto fra il tempo ideale e quello ottenuto con grado di parallelismo n

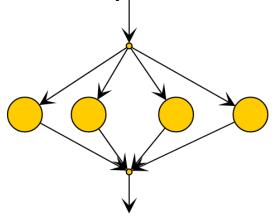
Forme di parallelismo: pipeline



- Riceve uno stream in dati in input
- Calcola dei risultati e li manda sullo stream di output
- Ogni stadio calcola un risultato parziale che diventa input per lo stadio successivo
- Stadio j calcola f_j
- Pipeline calcola $f_m(f_{m-1}(...(f_2(f_1(x))..))$

- Tempo di servizio
 (grado di parallelismo n)
 Ts = max{T_i}
 T_i= tempo di servizio stadio I
- Tempo di completamento (grado di par n e m tasks) $Tc(n,m) = \Sigma Ti + (m-1) max\{Ti\}$
- Massimo speedup numero degli stadi

Forme di parallelismo: task farm

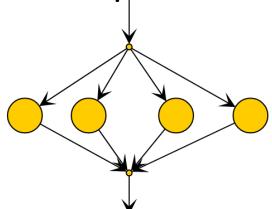


- Riceve uno stream in dati in input
- Calcola dei risultati e li manda sullo stream di output
- Ognuno dei worker calcola la stessa funzione f sui dati che riceve in input
- La politica di schedulazione dei task in input può essere round robin, a richiesta o altro
- La politica di raccolta dati può mantenere o meno l'ordinamento di ingresso

• Tempo di servizio (grado di parallelismo n) $Ts = max\{T_{sched}, T_{coll}, T_{w}/n\}$ T_{w} = tempo di servizio del worker n = numero di worker

- Tempo di completamento (grado di par n e m tasks) $Tc(n,m) = m * T_s = m * T_w / n$
- Massimo speedupn

Forme di parallelismo: map



- Riceve uno dato in input
- Divide il dato in sottotask
- Ognuno dei worker calcola la stessa funzione f sul sottotask che riceve in input
- La politica di schedulazione dei task in input può essere round robin o altro
- Quando tutti I worker hanno finito, I risultati dei sottotask vengono utilizzati per ricostruire il risultato finale (normalmente avente la stessa struttura del dato in input)

Latenza

(grado di parallelismo n) $Tc = T_{split} + T_{seq}/n + T_{merge}$ $T_{seq} = tempo di calcolo sequenziale$ n = numero di worker

Massimo speedupn

• Tempo di servizio (grado di par n e m tasks) $Ts = max\{T_{split}, T_{seq}/n, T_{merge}\}$

Tipi di parallelismo

 Temporale / spaziale (libro di testo) pipeline / map

- Data / Stream parallel {map} / {pipeline, farm}
 - Data parallelism: riduce latenza (se stadio di computazione stream parallel => di conseguenza riduce tempo di servizio)
 - Stream parallelism: aumenta throughput

Composizione

- Normalmente:
 - Componenti di una computazione stream parallel possono essere
 - Data parallel
 - Stream parallel
 - Sequenziali
 - Componenti di una computazione data parallel possono essere
 - Data parallel
 - Sequenziali
- Misure primitive si compongono di conseguenza:
 - Pipe(Seq(Latenza=L1), farm(Seq(Latenza=Lw), n worker), Seq(Latenza = L3))
 - Ts = max{T1, T2, T3} = max{L1, max{Tsched,Lw/n,Tcoll},L3}

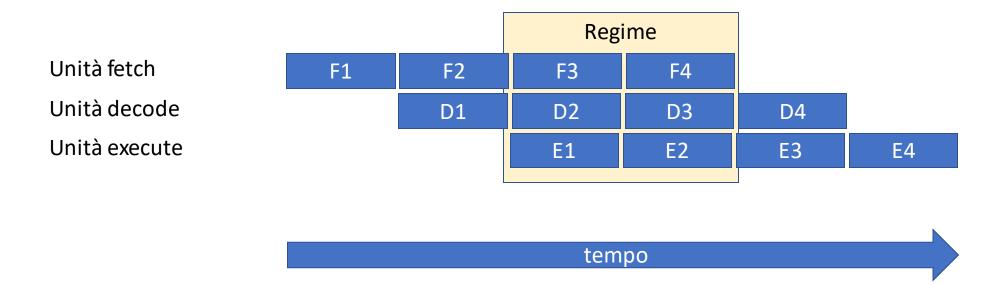
Rimozione colli di bottiglia

- Collo di bottiglia
 - Parte della computazione che rallenta tutta la computazione

- Esempio
 - Pipeline con 3 stadi
 - Stadio lento => collo di bottiglia
 - Renderlo un farm
 - Utilizzare data parallelism (se possibile)

Esempio (pipeline: parallelismo temporale)

• Fetch, decode, execute



Esempio map (parallelismo spaziale)

Esecuzione di istruzioni vettoriali (SIMD, SSE, AVX, ...)
 forall k: x[k] = y[k]+z[k]

